

Dinâmica espaço-temporal da contaminação pelo rompimento da Barragem de Fundão próximo à foz do Rio Doce

RESUMO

Análise dos efeitos locais, em perceptiva temporal próximos a foz do rio Doce, pelo contato do desague de rejeitos oriundos do rompimento da barragem de Fundão MG. Pelos índices espectrais, mais precisamente o NDWI, determinou-se a situação; antes, durante e depois, do lançamento dos efluentes. Por dois métodos de amostragem; aleatório e regular, avaliou-se por métodos geoestatísticos, posições onde ocorreu maior variabilidade do índice espectral estudado. Estabelecendo dois modelos matemáticos (superfície de tendencia de 3º e krigagem) para estudos mais aprofundados. Por fim, em painel temporal, demonstrou-se a variabilidade de vários índices(NDVI, IVEG, NDWI, EVI, MNDWI, oxido de ferro), a percepção destes alvo mensurado por sensor remoto Landsat 8.

Palavras chaves : *Espaço-temporal; índices espectrais ; superfícies de tendencia ; geoestatística*

Spatiotemporal dynamics of contamination from the Fundão Dam collapse near the mouth of the Rio Doce

ABSTRACT

Analysis of local effects, in temporal perception near the mouth of the Doce River, by the contact of the discharge of tailings from the rupture of the Fundão MG dam. By the spectral indices, more precisely the NDWI, the situation was determined; before, during and after the release of the effluents. By two sampling methods; random and regular, the positions where the greatest variability of the spectral index studied occurred were evaluated by geostatistical methods. Establishing two mathematical models (3º trend surface and kriging) for more in-depth studies. Finally, in a temporal panel, the variability of several indices (NDVI, IVEG, NDWI, EVI, MNDWI, iron oxide) was demonstrated, the perception of these targets measured by a Landsat 8 remote sensor.

Keywords:Spatiotemporal; spectral indices; trend surfaces; geostatistics

Sumário

1	Introdução	3
2	Objetivos	4
2.1	Objetivos Gerais	4
2.2	Objetivos Específicos	4
3	Material e Método	5
3.1	Local de Estudo	5
3.2	Sensoriamento Remoto	6
3.3	Amostragem	7
3.4	Geoestatística	9
3.5	Dados Espaço - Temporal	9
3.6	Operações	10
3.6.1	Índices Espectrais	10
3.6.2	Geostatística	12
3.6.3	Estatística clássica -validação cruzada do modelo predito	14
4	Resultados	15
4.1	Índices espectrais	15
4.2	Geoestatística	16
4.3	Análise da validação cruzada do Modelo	20
4.4	Dinâmica temporal	21
5	Discussão	22
6	Conclusão	23
	Referências	23

Realização



Apoio Institucional



1 Introdução

O rompimento da barragem de Fundão, no povoado de Bento Rodrigues, município de Mariana, Minas Gerais, em 5 de novembro de 2015, lançou rejeitos de mineração de ferro na bacia hidrográfica do Rio Doce, causando uma série de prejuízos, incluindo perdas de vidas humanas e contaminação ambiental a jusante do corpo hídrico.

O volume de rejeitos liberado, contendo material estranho ao bioma característico da região, alterou simultaneamente as condições dos corpos hídricos e da vegetação marginal..

A cobertura desse evento foi amplamente noticiada pela imprensa nacional e internacional, incluindo veículos como *The Wall Street Journal*, *The Guardian*, *Le Monde*, entre outros.

Em acordo com o Ministério público (MP) e sua controladora a anglo-australiana *BHP Billiton*, baseado nos princípios de poluidor pagador, trazidos no artigo 3º, inciso IV, da Lei 6.938/81 (Política Nacional do Meio Ambiente), estabeleceram um termo de pactuação e posterior outra repactuação. A repactuação atendendo o princípio do poluidor-pagador, visa o dever de corrigir, recuperar e/ou eliminar os efeitos negativos já produzidos em uma contaminação antrópica.

A repactuação, utilizando ferramentas de cartografia, acordo com (MAGRI et al., 2023, p 79), determinando ações de reparação aos atingidos e a amplitude de localização geográfica em que ocorram ações de contaminação, e por meio de direta interveniência judicial e administrativa, e a fundação criada para reparação do rio Doce, denominada Fundação Renova.

Passados nove anos, com base na data de 23 de maio de 2025, e com a redução da atenção midiática sobre o desastre, este estudo propõe como objeto de pesquisa avaliar se os efeitos da contaminação por rejeitos ainda podem ser detectados por sensores orbitais e se há alterações passíveis de observação por esses instrumentos. Esses aspectos são objetos de perícia ambiental, conforme descrito por (ARANTES; ARANTES, 2016, p.130)

A justificativa deste estudo, motivado pela delimitação estabelecida pela repactuação entre o Ministério Público e a Fundação Renova. Esta foi a resposta à calamidade, as partes envolvidas – a Samarco, suas acionistas Vale e BHP Billiton, a União e os governos de Minas Gerais e do Espírito Santo – firmaram o Termo de Transação e Ajustamento de Conduta (TTAC) em 2 de março de 2016. Com base neste acordo, foi criada a Fundação Renova em 2016, uma entidade privada com a missão de conduzir as 42 ações e programas socioeconômicos e socioambientais definidos para a reparação. No entanto, ao longo dos anos, a atuação da Fundação Renova foi alvo de diversas críticas e gerou um passivo significativo de 85 mil processos judiciais, evidenciando a necessidade de uma solução mais eficaz e abrangente.

- R\$ 38 bilhões já desembolsados desde a tragédia.
- R\$ 100 bilhões em "dinheiro novo", destinados aos entes públicos para custeio de medidas compensatórias e projetos socioambientais e socioeconômicos.
- R\$ 32 bilhões em "Obrigações de Fazer", que incluem indenizações individuais,

Realização



Apoio Institucional



reconstrução de comunidades e recuperação de áreas degradadas, sem um teto financeiro pré-determinado, devendo a Samarco comprovar a conclusão de cada obrigação.

Com base na exposições acima, as seguintes hipóteses são formuladas:

- H_1 : O sensor orbita Landsat 8 consegue identificar alterações em respostas em radiância na época do ocorrido, e seus efeitos ainda podem ser mensurados.
- H_2 : Se este sensor orbital consegue distinguir alterações espectral do fenômeno, e o mesmo consegue determinar sua amplitude espacial geográfica, de forma a caracteriza-la.
- H_3 : Existe resquícios desta contaminação no local, e que podem ser mensurados.

2 Objetivos

2.1 Objetivos Gerais

O objetivo deste estudo é comparar medidas de reflectância no solo, em vegetações e na água, utilizando a tecnologia de sensoriamento remoto (SR), para diferenciar as condições geográficas antes, durante e após o evento em análise. Além disso, busca-se verificar a possibilidade de identificar locais com contaminações e/ou alterações antrópicas decorrentes do desastre de Mariana

2.2 Objetivos Específicos

A estruturação das informações será dividida em etapas. Inicialmente, serão obtidos dados por meio de imagens orbitais, armazenados, processados e analisados. Para isso, será utilizada a plataforma de acesso livre da "Google Earth Engine (GEE)". E como descreve em (KUMAR; MUTANGA, 2019, p.1), motivados por essa plataforma permitir o acesso a séries de imagens Landsat a partir de 2008.

O segundo passo consiste na realização de uma amostragem sistemática em locais geográficos específicos, utilizando valores de reflectância obtidos pela plataforma GEE. Essa abordagem possibilitará a construção de um painel temporal da ocorrência do evento.

Por fim, a modelagem do fenômeno será realizada com base em critérios de validação estatística, que fornecerão subsídios para uma amostragem mais refinada, utilizando métodos probabilísticos aplicados a classes de uso do solo em zonas específicas

Realização



Apoio Institucional




3 Material e Método

3.1 Local de Estudo

A região estudada está localizada na microrregião administrativa central do estado do Espírito Santo, próxima ao delta do rio Doce, em uma planície fluvial composta por depósitos quaternários, dividida em porções de natureza lagunar e fluvial, ambas caracterizadas por processos de acumulação. Os solos predominantes na área incluem Cambissolos Eutróficos e Organossolos, sem influência marinha.

O relevo da região é predominantemente plano, com declividade inferior a 2% em toda a sua extensão. Quanto ao uso do solo, podem ser identificadas seis classes principais: (1) áreas de cultivo com culturas como mamão, coco-da-baía, cana-de-açúcar e abacaxi, entre outras; (2) áreas de reflorestamento, em proporção semelhante às áreas cultivadas; (3) pastagens; (4) brejos; (5) porções esparsas de solo exposto; e (6) pequenas áreas de corpos d'água, como açudes.

Figura 1: Zona hachurada, região da repactuação



Fonte: Elaborado pelos Autores (2025)

A escolha desta região como objeto de estudo justifica-se pela diversidade de usos do solo mencionada, que permite a análise da área sob a perspectiva da repactuação ambiental. Além disso, a região possibilita a observação de eventos climáticos extremos, como inundações (conforme ilustrado na Figura 2), e o estudo do encontro do fluxo de rejeitos com a foz do rio Doce e o oceano Atlântico, destacado nas figuras correspondentes. 3 e 4

Figura 2: Anoln 2013



Figura 3: Ano de 2016



Figura 4: 2016 NIR



Fonte: Elaborado pelos Autores (2025)

Com base na análise da situação física e considerando que o objeto da repactuação abrange uma área de 5.723,26 km², o local de estudo aprofundado corresponde

Realização



Apoio Institucional



cobreap.com.br



producao@alvoeventos.com.br

a uma extensão de 10.000 hectares. Assim, o instrumento mais adequado para a pesquisa é o uso de imagens aéreas ou orbitais, com preferência por estas últimas. O delineamento da pesquisa será amostral, de caráter qualitativo-descritivo, com a variável mensurada longitudinalmente em um painel temporal

Para minimizar questionamentos técnicos ou sociais, a metodologia deve ser delineada de forma totalmente replicável, tanto em sua estrutura quanto em seu conteúdo. A base teórica será fundamentada, majoritariamente, em publicações internacionais, como livros científicos. As imagens utilizadas como base de dados serão disponibilizadas gratuitamente à comunidade científica. Além disso, os aspectos substantivos serão priorizados, com afirmações fundamentadas em resultados matemáticos. Por fim, a pesquisa adotará uma abordagem adjetiva, classificando a situação antes, durante e após o evento extrínseco.

3.2 Sensoriamento Remoto

A obtenção de dados obtidos por sensoriamento remoto, o princípio básico de sensoriamento remoto, disposto por (REDDY, 2008, p. 24) é "ciência e a arte de se obter informação sobre um objeto, área ou fenômeno o através de uma análise de dados adquiridos sem o contado com o objeto, fenômeno que se está sendo investigado". Acrescenta-se ainda que em (JENSEN, 1949, p. 7) descreve que além das coordenadas x,y,z e profundidade, o sensoriamento remoto possibilita a análise da biomassa, a temperatura, e suas misturas contidas, e ainda outras.

De mesma forma em (LILLESAND; KIEFE, 2016, p.1), "a ciência e arte de obter informações a respeito de um objeto, área ou fenômeno pela análise de dados adquiridos por um sistema que não se encontra em contato com o objeto, área ou fenômeno sob investigação"

A captação dessas informações, ocorre por meio de dados, reflectividade do objeto observado - superfície terrestre -, ocasionado pela emissão de energia eletromagnética emitida pelo sol, sendo parte absorvida pela superfície terrestre e parte reflectida a atmosfera. e em ambos efeitos são captados por sensores orbitais.

Diferentes sensores, com atributos e processos construtivos diferentes e inerentes, segundo (CENTENO, 2003, p. 20) armazenarão o espectro eletromagnéticos, comprimento de ondas de variável contínua, em canais e/ou bandas específicas. Esses canais, comprimento de ondas em faixa distintas divididas e classificadas, a partir deste momento em variável discreta, são denominadas **resolução espectral**, ainda em (CENTENO, 2003, p. 54) a maior ou menor capacidade de registrar diferenças espectrais entre os alvos e a medida desejada. Considerando as perdas atmosféricas, variações temporais, e as propriedades inerentes dos corpos imageados; composições químicas.

O processo de manipulação e classificação da variável discreta e seu espaço multidimensional e sua coordenada **DN(x,y)**, como em (SCHOWENGERDT, 2007, p. 183), possui nome próprio denominado em língua inglesa "**Spectral Tranforms**". E dentro destas operações matemáticas para se obter melhorias da informação destas imagens, agora em (LILLESAND; KIEFE, 2016, p. 485), sejam estas operações: manipulação de contrastes, correções geométricas, correções radiométricas, classificação

Realização



Apoio Institucional




entre outras. Existe um processo a ser desenvolvido neste estudo, denominada diferenças normalizadas e índices.

Voltando a (CENTENO, 2003) e este citando (CHUVIECO, 2008, p.339), é a combinação entre bandas, obtendo uma nova imagem, com características distinta, de forma a realçar a informação dos alvos e suas variações químicas e bióticas.

Esta imagem, georreferenciada, mesmo sem o processo de classificação automática ou manual, pode ser entendida em estar em perspectiva tri-dimensional (3-D) por banda com características (x,y, valor discreto), mas pode incorporar a quarta dimensão (4-D) o tempo.

Figura 5: Quatro dimensões em cubo de dados : x,y,banda, e tempo



Fonte: Em (PEBESMA; BIVAND, 2023, p.60)

A partir do conceito, que compreendemos como cubo de dados, deve-se ter em mente que a variação da atributo do objeto a ser mensurado, este deve ser coletado. Então surge a necessidade de amostragem, melhor dizendo, um plano de amostragem, livre de vieses, este detectando a variedade temporal, em sua estrutura de posicionamento, incluindo a principal variedade medida, que em nosso caso é a reflectância e suas composições e combinações .

3.3 Amostragem

O conceito de amostragem, e mais especificamente uma amostra, para (KRISHNASWAMY; SIVAKUMAR; MATHIRAJAN, 2012, p. 281) deve ser utilizado quando **não é possível ou prático** utilizar observação do fenômeno estudado em toda a população, este empecilho pode ser ocasionado por diferentes formas, sejam ele associados a localização geográfica, população numerosa, ou mesmo custo de aquisição elevado.

Acrescenta-se a estes fenômenos, temos o tempo, pois se a alteração já ocorreu existe a dificuldade de rever eventos que foram alterados, e por isso devemos ter métodos de obtenção desta informação na época estuda, e por isso utilizamos às técnicas de sensoriamento remoto, e processamento de imagem para obtermos a informação.

E ao estabelecimento do plano de amostragem, devemos ter em mente o conceitos de esta atividade o (BOLFARINE, 2005, p.2), o pesquisador planeja, executa, corrige e analisa o procedimento a ser proposto e usado. Tendo como base a técnica

Realização



Apoio Institucional



cobreap.com.br




producao@alvoeventos.com.br

de mensuração, e a questão respondida.

A escolha do método de amostragem livre de viés, e que o erro de estimativa seja minimizado, está diretamente ligado a estrutura de amostragem. Em nosso estudo optamos primeiramente pela estratificada aleatória por classe de uso do solo, de acordo com (LOPES, 2002, p.191), e posterior de sistemática, estabelecimento de um **grid**, por grades regulares.

O objetivo da primeira técnica, segundo (LOHS, 2022, p.22) quando o tipo de amostragem por estratificação pode ser utilizada em regiões específicas que desejamos obter informação, em nosso caso a variação de reflectância temporal em classes de uso do solo específica. Já na segunda possibilitando que todos os fenômenos mensurados, tenham a mesma possibilidade de ser coletado, e em ambas livres de vieses.

Figura 6: Amostragem em classes



Fonte: Elaborado pelos Autores (2025)

A metodologia de planejamento e direcionamento baseada na relação entre amostras e classes de uso do solo é um procedimento comum entre profissionais da área de cartografia. Diversos estudos descrevem essas atividades; no entanto, segundo os autores, os trabalhos mais relevantes destacam os conhecimentos apresentados por Congalton (CONGALTON; GREEN, 2009, p.79), que vinculam cada classe de uso do solo à quantidade de amostras correspondente. Além disso, Ariza (LOPES, 2002, p.135) complementa ao determinar o tamanho amostral e o erro com base na estimativa, enquanto (LO-

PES, 2002, p.192-196) ilustra os quantitativos, em metros quadrados, de cada classe de uso do solo e o número necessário de fragmentos por classe. Esses fundamentos permitem a aplicação de fórmulas estatísticas, como a equação (1), em quantitativo de classes conhecidas, para determinar o número de amostras por classe, considerando o erro, o nível de confiança estipulado e a representação gráfica demonstrada na Figura 6.

Realização



Apoio Institucional



Onde: n - e o tamanho da amostra ;
 E - e o erro amostral (precisão) σ e a variância da população;
 Z_c - é a abscissa da distribuição normal padrão, fixado um nível de confiança C ;
 N - E o tamanho da população

$$n = \frac{Z_c^2 * \sigma^2 * N}{E^2 * (N - 1) + Z_c^2 * \sigma^2} \quad (1)$$

3.4 Geoestatística

Segundo (TOLOSANA-DELGADO; MUELLER, 2021, p.1) a modelagem geoes-tatística, tem um papel chave na análise da evolução de eventos distribuídos sobre a superfície da terra e ciências da engenharia ligadas a recursos naturais.

A utilização de malha regularas, também conhecido como "**grid**", como exposto em (ANDRIOTTI, 2009, p.83), tem a função de através de pontos amostrados, estabe-lecer um mapa de forma continua, passível de estimar valores dentro deste estrutura e até estabelecer extrapolações. Isso é possível através de técnicas de interpolação, voltando a (LOPES, 2002, p.304), caracterizando o papel da interpolação, para este autor, "*a interpolação e uma transformação que permite estimar valores desconhecidos a partir de valores conhecidos em posições certas*".

Isso ocorre por que, conforme (YAMAMOTO; LANDIN, 2013, p.21), o fenômeno espacial compreende um conjunto de valores possíveis da variável de interesse, e a sua distribuição e variabilidade está dentro de respectivos domínios sejam eles 2-D ou 3-D. Voltando a (ANDRIOTTI, 2009, p.95), pode ser caracterizada como variável regionalizada.

Em (WEBSTER; OLIVER, 2007, p.37) os fenômenos físicos naturais, possuem variação determinística e sistemática, e estão relacionados a campo da matemática e geometria. E através destas das técnicas, podemos estabelecer predicções e in-terpolações entre elas a polígonos de Thiessen, inverso da distancias, superfícies de tendencias, splines e por fim a krigagem.

3.5 Dados Espaço - Temporal

O paradigma espaço tempo, para (MATEU; MULLER, 2013, p.2), este processo pode ser assumido como um modelo estatístico, e ser representado pela equação:(2)

$$Z(x, s, t) = \eta(x, (s, t), s.t.\beta) + \epsilon(x, s, t) \quad s \in D, t \in T. \quad (2)$$

Onde s corresponde a uma localização espacial, t um momento temporal, x potencialidades dependentes de regressões , e η uma parametrização do modelo.

Para outro autor, (BIVAND; PEBESMA; GOMEZ-RUBIO, 2013, p.151) o inte-resse e local estudado, pode ser separado em: ponto ou área, tempo ou intervalo, e por fim a ocorrência medida. Já que possuem diferentes propriedade e qualidade também distintas

A etapa inicial consiste na obtenção de dados (imagens), que podem ser ad-quiridos por meio de plataformas como o Google Earth Engine (GEE), agilizando o

processo de produção de informações. Esses dados podem ser integrados à implementação de scripts que automatizam a busca por cenas em datas específicas, permitindo também o cruzamento com outras informações para análises mais precisas, como a avaliação da cobertura e uso do solo atual (Figura 6). Além disso, é possível selecionar aspectos como o percentual de cobertura de nuvens e o intervalo espaço-temporal das informações obtidas.

```

1   var dataset = ee.ImageCollection('LANDSAT/LC08/C02/T1_L2')
2   .filterDate('2013-05-01', '2025-05-01');
3   // Applies scaling factors.
4   function applyScaleFactors(image) {
5       var opticalBands = image.select('SR_B.').multiply(0.0000275).add
6       (-0.2);
7       var thermalBands = image.select('ST_B.*').multiply(0.00341802).add
8       (149.0);
9       return image.addBands(opticalBands, null, true)
10      .addBands(thermalBands, null, true);
11      }
12      dataset = dataset.map(applyScaleFactors);
13      var visualization = {
14          bands: ['SR_B4', 'SR_B3', 'SR_B2'],
15          min: 0.0,
16          max: 0.3,
17      };
18      Map.setCenter(-39.93696, -19.5597, 8);
19      Map.addLayer(dataset, visualization, 'True Color (432)');

```

Listing 1: Código de obtenção de imagens multiespectrais Landsat8 plataforma Google Earth Engine Code em linguagem JavaScript.

3.6 Operações

3.6.1 Índices Espectrais

A operação com dados raster, dados binários, para (DORMAN, 2014, 106) "*grids de valores numéricos*", e estes estão agrupados bandas espectrais, e para (LIU, 2015, p.178 e p.181) podem sofrer operações e conversões unárias, e sujeitas a operações comuns matemáticas com: adição, subtração, multiplicação, divisão, módulos. Inclui-se também operações relacionais e booleanas, lógicas e combinatórias.

Neste contexto, inicia-se nossas atividades. com a compreensão de índices espectrais, devemos entender, que são operações matemáticas entre bandas, sendo amplamente difundidos em diferentes meios das literatura técnica. Ao nosso estudo de alteração do meio físico, e conhecendo que os principais elementos encontrados no local são: solo, a água e a vegetação, entende-se que os índices são capazes meios capazes de ser sensibilizados pelas variações destes elementos. E ao utilizamos as operações algébricas (3), (4) e (6), de combinação de bandas que estão dispostas em (THENKABAIL, 2016, p.165) e equação (5) (THENKABAIL, 2016, p.7).

$$NDVI = \frac{nir - red}{(nir + red)} \quad (3)$$

Realização



Apoio Institucional



$$NDWI = \frac{green - nir}{(green + nir)} \quad (4)$$

$$EVI = \frac{G * (nir - red)}{nir + 2,4.red + 1} \quad (5)$$

$$SAVI = \frac{(nir - red) * (1 + l)}{(nir + red + L)} \quad (6)$$

Onde, "red" corresponde a banda vermelha, "green" a banda verde, "NIR" o infravermelho próximo, e o "L" correção de reflectâncias do solo.

Para manipulação destes dados utilizando a linguagem R na versão 4.5, e ambiente de desenvolvimento junto ao notebook Jupyter, somente devido ao ambiente gráfico junto ao navegador de internet, em termos corretos são chamados em língua inglesa de "browser", mesmo sendo possível realizar todas as operações junto ao RStudio 2015.05. Necessitamos esclarecer que todos as bibliotecas de funções no R são chamadas de "package", e ao carregarmos o pacote, "**raster**" e "**terra**", ao software pelo comando.

```

1 library(raster)
2 library(terra)
3 raster_template <- terra::rast("D:\\IMAGENS2\\lc_20160202.tif")
4

```

Listing 2: Código para carregar imagens em linguagem R

O package "RSToolsBOX", atualmente na versão, 1.0.2.1, traz uma série de ferramentas para trabalharmos com dados de sensoriamento remoto, tanto que este vem incorporado com as funções e/ou equações matemáticas nas 2 a 5. E dentro destas funções temos a função "**spectralIndices**", usada no script a seguir :

```

1 VI_20131023 <- spectralIndices(raster_template, blue = "Layer_1",
  gree = "Layer_2", red = "Layer_3", nir = "Layer_4", swir2 = "Layer_5",
  indices = c("NDVI", "NDWI", "EVI2", "MSAVI"))
2 VI_palette <- brewer.pal(n = 10, name = "Spectral")
3 spplot(VI_20131023, col.regions = VI_palette, cuts = 6, col = "
  transparente")
4

```

Listing 3: Código para obter índices em linguagem R

Este procedimento, visto que as duas imagens estão georreferenciadas ao mesmo sistema de coordenadas, é observarmos por meios matemáticos a variação da reflectividade do mesmo ponto, por índices físicos medidos pelo sensor remoto, diminuindo a subjetividade do observador, e ao mesmo tempo qualificar e variância temporal da superfície.

Tendo a imagens 7 a 9, estas em nível de cinza, e iniciarmos operações algébricas de obter diferenças entre duas imagens temporais em Figuras 10 a 12.

O próximo passo, ao inserir o "grid", malha regular espaçada a inicialmente a 1.600(mil e seiscentos) metros, para iniciar as operações de interpolação. Duas respostas desejamos obter nesta etapa, uma superfície contínua, e uma superfície que

seja possível demonstrar direções do fenômeno estudado. E por fim, sua validade.

Por que de forma complementar, a validação cruzada, permite verificar o modelo gerado, esta aderente, ao observado e calculado. E por isso as técnicas de interpolação com métodos geoestatísticos se completam.

3.6.2 Geostatística

A análise das características da variabilidade espacial, que também pode ser chamada de "análise estrutural", tem o objetivo a determinação com a previsão de valores de atributos em locais não amostrados, uma simulação, para estes valores não incorporados. Produzindo um modelo, em forma de superfície contínua, Figura 20

Inicialmente, utilizou-se a quantidade de amostras obtidas na equação (1). Mas os resultados em primeira análise não foram satisfatórios. E portando optou-se pela amostragem em grid.

Inseridos os vértices do grid, pela biblioteca(package) **sp**, quase todas as ferramentas para interpolação tem como passo fundamental o carregamento e perfeito funcionamento da biblioteca **stars** e mais especificamente o **gstat**, Posto que a interpolação ocorre entre a coordenadas geográfica e o valor mensurado. Além do mais, que este possibilita realizarmos a interpolação pelo inverso das distância, superfícies de tendência e krigagem. O procedimento no R é:

```

1 library(stars)
2 library(gstat)
3 modelo_raster <- raster("00_dados\\SUBTRACAO.tif", values=FALSE)
4 interpolado <- gstat::gstat(formula= variavelmensurada~1, locations =
5   arquivodogrid, set = parametrosdomodelo )

```

Listing 4: Interpolação em linguagem R

A terceira linha, é a imagem subtraída das alterações temporais, a ser demonstrada na Figura 12, sendo necessária a todos os procedimentos inclusive a krigagem e superfícies de tendência.

O resultado deste modelo, uma superfície contínua, já nos possibilita avaliarmos o **1º Critério** numérico. Neste caso raiz do erro médio quadrado, e a estimativa da porcentagem da variação explicada R^2 .

E neste momento, o processo torna-se interativo, testando os vários métodos de interpolação(simples interpolação, inverso das distância, inverso da distância com pesos ponderados, superfície de tendência e a krigagem). Enfatizando, por termos os valores medido e estimado todos as medidas de variabilidade (media, mediana, moda, medidas de dispersão, distribuição de frequência ...)

Profissionais que desenvolvem modelos matemáticos, muitas vezes apresenta a dificuldades em estabelecer as funções de transformação para normalizar seus dados. A inclusão do package/biblioteca **bestnormalize**, auxiliou demasiadamente em nosso modelo, realizando suas estimativas automaticamente. A sua implementação a linguagem R procedeu-se:

Realização



Apoio Institucional



```

1 library(bestNormalize)
2 modelo_normal <- bestNormalize(arquivodogrid\${variavelmensurada} )
3

```

Listing 5: normalizacao do modelo em linguagem R

Segundo (YAMAMOTO; LANDIN, 2013, P.35) o termo variograma, ou semivariograma, ocorre uma confusão terminológica de acordo com a literatura utilizada, para estes autores preferimos o exposto por (FERREIRA, 2014, p.228).

Semivariogramas são modelos gráficos utilizados para se detectar o grau de dependência espacial entre dados geográficos em diferentes intervalos de distâncias crescentes, predefinidos e contados a partir de uma posição espacial inicial qualquer. Este modelo se constitui na curva da função de variância $\gamma(h)$ dos dados, onde h é um intervalo de distância até uma origem arbitrária(..)

A parcela da modularização dos nossos procedimentos e análise do variograma para nossos dados foram obtidos pelo código a seguir.

```

1 library(gstat)
2 variograma <- gstat::variogram(variavelmensurada~1, arquivodogrid)
3

```

Listing 6: Producao do variogramas em linguagem R

Existe a possibilidade da realização por procedimentos automáticos, com a utilização da krigagem, agora utilizando o package, sendo os valores da listagem em **automap** que também faz de forma automatizada. start_vals somente para apresentar no figura desejada.

```

1 library(automap)
2 variogram\_auto <- autofitVariogram(variavelmensurada~1, arquivodogrid,
3   start\_vals=c(variogramar\${nugget}, variogramar\${cov.pars[2]}, variograma\
4   \${cov.pars[1]}))

```

Listing 7: Auto ajuste do Variograma em linguagem R

O mapa variográfico Figura 21, das covariâncias em:

```

1 var_exp_map <- gstat::variogram(g, cutoff = 10000, width = 1400, map =
2   T)
3 plot(var_exp_map, main = "Mapa Vaiografico")

```

Listing 8: Mapa variografico em linguagem R

No entanto, a criação do variograma, de forma manual em que a escolha do modelo que melhor se enquadra aos valores calculados ($\gamma(metros)$). Justo que, proporciona a compreensão da natureza espacial da variabilidade, a densidade dos dados, o agrupamento e tendências das amostras. Procedimento em Script a seguir:

Realização



Apoio Institucional




```

1  fit.sph <- gstat::fit.variogram(var_exp, vgm(contril, "Sph", Range ,
2    0.01))

```

Listing 9: Variograma utilizando função esférica em linguagem R

A verificação se os valores preditos e observados

```

1  xvalid.sph <- krige.cv(SUBTRACA0~1, locations = img1, model = fit.sph )
2

```

Listing 10: Validação cruzada em linguagem R

```

1  krigagem_auto <- autoKrige(SUBTRACA0~1, modelo_grid, new_data=modelo_
2    grid, start_vals=c(variofit_geor$nugget, variofit_geor$cov.pars[2],
    variofit_geor$cov.pars[1]))

```

Listing 11: Krigagem em linguagem R

3.6.3 Estatística clássica -validação cruzada do modelo predito

O processo da modelagem espacial do fenômeno, com o sem a krigagem, teremos uma estrutura tabular "dataframe" com as disposicao da Tabela 1. Que nos possibilitará tratarmos com um modelo matemático, e com isso os critérios e da metodologia clássica, para avaliarmos a sua qualidade, o **2º critério** numérico e gráfico.

Inicialmente pelo teste da normalidade principal, valor numérico. E posterior por

Tabela 1: Resultado do Predição

pred	var	observed	residual	zscore	fold
-0.1567124	0.00908	0.2220	-0.0653	-0.6854	1
-0.2132872	0.007764321	-0.2007164	0.01257077	0.1426626	2
...
-0.2007443	0.007608483	0.2861705	-0.08542618	-0.9793590	12

Fonte: Elaborado pelos Autores (2025)

testes gráficos, ambos mostrados na seção 4.3. Pela quantidade de dados utilizou-se o teste de Kolmogorov Smirnov, como demonstrado pelo script a seguir.

```

1  lillie.test(valida3$pred)
2

```

Listing 12: Teste Lilliefors (Kolmogorov_Smirnov) em linguagem R

E o teste numérico de correlação pelo método de Pearson, pelo script:

```

1  cor.test(Mod_esfe$pred, Mod_esfe$observed, method = "pearson")
2

```

Listing 13: Teste de correlação em linguagem R

Realização



Apoio Institucional



Realizado a análise exploratória dos dados, estabelecido o modelo matemático que melhor se ajusta aos fenômenos, podemos iniciar a inferência sobre nossos resultados.

4 Resultados

4.1 Índices espectrais

O critério inicial de nosso procedimentos se estabeleceu inicialmente pela estabilidade dos indicadores bióticos do local. Tendo o estado inicial em $T_0 = 2013$, sem ação antrópica do fenômeno, em $T_1 = 2016$ o local já sofrendo a ação do fenômeno externo, e o conjunto da situação, mais próximo do momento atual em que o fenômeno se encerrou $T_2 = 2023$.

Devido a situações como efeitos atmosféricos de cobertura de nuvens, brumas. Impossibilitou a obtenção de imagens de resoluções temporais menores.

Figura 7: 2013




Figura 8: 2016





Figura 9: 2023



Fonte: Elaborado pelos Autores (2025)

Neste conjunto de imagens em nível de cinza, escolhido a paleta de cores "RdYlGn" do "package ViridisLite" nas Figuras 10 a 12, cujas as medidas pelo sensor e transformadas aos índices espectrais, demonstram que a água ocorreu maior variação neste índice medido e calculado, e por nisso o índice NDWI foi escolhido para uma análise mais priorizada.

Realização



Apoio Institucional



Figura 10: NDWI 2016

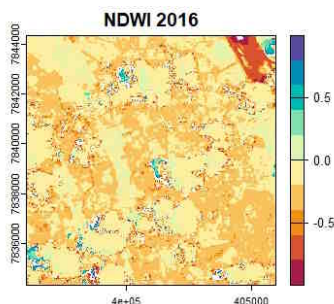


Figura 11: NDWI 2023


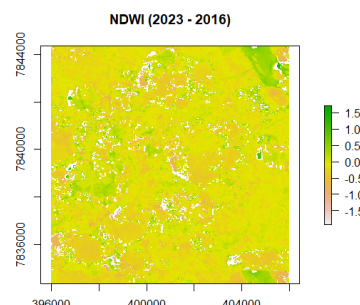


Figura 12: Diferenças no NDWI



Fonte: Elaborado pelos Autores (2025)


Ao destacarmos o índice NDWI nas duas imagens com diferença temporal de 8(oito)anos, temos a Figura 12 e nesta a atenção pode ser observada no canto superior direito, e em outras superfícies com maior presença de água, como brejos e açudes, a alteração contrastante destas diferenças.

4.2 Geoestatística

Neste momento, a percepção do objeto observado ser uma superfície, quase continua(excluídos vazios radiométricos), torna-se inerente ao fenômeno de estudo. E por ser uma superfície, com valores máximos, mínimos, direção, desvio padrão e variância do valor do índice com coordenada (x,y). Deve ser tratada como tal, e ser analisadas por técnicas da geoestatística.

Ao decimo sétimo e oitavo paragrafo da seção 3, ao descrevermos a estrutura de amostragem, e ao parágrafo anterior que compreendemos a estrutura do fenômeno com uma variável regionalizada, e por isso voltamos a (YAMAMOTO; LANDIN, 2013, p.10) :

Figura 13: Amostragem em grid



Fonte: Elaborado pelos Autores (2025)

Realização



Apoio Institucional



Os métodos geoestatísticos fornecem um conjunto de técnicas necessárias para entender a aparente aleatoriedade dos dados, os quais apresentam, porém, uma possível estruturação espacial, estabelecendo, desse modo, uma função de correlação espacial.

Ainda em (YAMAMOTO; LANDIN, 2013, p.19 e 20), o fenômeno estudado se comporta dentro de domínios, sejam em 2D ou 3D, e apresentam distribuição e variabilidade espaciais. A "metodologia da geoestatística se destaca ao oferecer a incerteza associada à estimativa"

Continuando em (YAMAMOTO; LANDIN, 2013, p.20 e 21), na "reprodução das característica do fenômeno espacial baseado em pontos amostrais é denominado interpolação ou estimativa". O processo de para inferir a distribuição e a variabilidade espacial, vai depender do tamanho da amostra e da distribuição espacial, e em nosso caso se estabeleceu tanto por aleatoriedade Figura 6 e Figura 13

Coletado os dados, e tabulados, necessitamos fazer a sumarização e análise exploratória, no entanto varias vezes verificamos situações que impossibilita termos conclusões sobre os seus resultados. E como em (WEBSTER; OLIVER, 2007, p.18), muitas variáveis ambientais, principalmente nas concentradas no solo, estão na forma de distribuição normal, de acordo com as "descoberta independentemente por De Moivre, Laplace e Gauss, mas Gauss parece geralmente levar o crédito por ela. E a distribuição é frequentemente chamada de "gaussiana".

Ainda em (WEBSTER; OLIVER, 2007, p.20), mas a utilização destes dados na formulação de modelos, apresentam dificuldades, podemos transformar os valores medidos a uma nova escala, "se necessário, transformar os resultados para a escala original ao final."

Na Figura 12 realizando operações de interpolação com a utilização do grid, conseguimos obter uma imagem com alguma normalidade, Figura 14. No entanto ao aplicarmos o **bestnormalize**, os resultado é surpreendente, tanto que apresentamos em Figura 15, e nos estimulou a geração do modelo matemático em 3D, Figura 16

Figura 14: Antes da normalização




Figura 15: Após a normalização





Figura 16: Perspectiva da Superfície



Fonte: Elaborado pelos Autores (2025)

Realização



Apoio Institucional



```

1 Best Normalizing transformation with 64 Observations
2 Estimated Normality Statistics (Pearson P / df, lower => more normal):
3 - arcsinh(x): 1.7857
4 - Center+scale: 1.8024
5 - Double Reversed Log_b(x+a): 1.7667
6 - Exp(x): 1.9929
7 - Log_b(x+a): 1.5042
8 - orderNorm (ORQ): 1.4643
9 - sqrt(x + a): 1.2955
10 - Yeo-Johnson: 1.2452
11 Estimation method: Out-of-sample via CV with 10 folds and 5 repeats
12 Based off these, bestNormalize chose:
13 Standardized Yeo-Johnson Transformation with 64 nonmissing obs.:
14 Estimated statistics:
15 - lambda = -3.643204
16 - mean (before standardization) = -0.09376124
17 - sd (before standardization) = 0.1402468
    
```

Listing 14: Sugestões de melhoria ao modelo em linguagem R

A produção inicial do variograma, com procedimentos em (BIVAND; PEBESMA; GOMEZ-RUBIO, 2013, p.224), com a caracterização mensurada e sua distância em visão inicial da análise em Figura 17

A escolha da função matemática que produza, e nos possibilite a explicar o modelo, pode ser encontrada em (TOLOSANA-DELGADO; MUELLER, 2021, p.90), e a mesma deve ser inserido os parâmetros e efeitos, com o significado em língua inglesa que são o patamar ("sill"), pepita("nugget"), comprimento("range") e sua contribuição("contribution") .

Figura 17: Escolha da função




Figura 18: Escolha da função





Figura 19: Modelo esférico



Fonte: Elaborado pelos Autores (2025)

Em todas as Figuras 17 e 20 que a estacionariedade inicia-se visualmente em aproximadamente em 0,9 e seu "range" em torno de 1300 metros

Realização



Apoio Institucional



Na Figura 17 o processo da escolha da função, na Figura 18 a função escolhida, e finalmente na Figura 19 a validação cruzada, com a regressão em homocedasticidade

Em Figura 20, temos a superfície da interpolação, com a análise da covariância do modelo, distribuído espacialmente em Figura 20, com procedimentos vistos em (TOLOSANA-DELGADO; MUELLER, 2021, p.47), e como cada variável, seus resíduos, e observação contribuem na explicação do modelo em 22

Figura 20: Superfície interpolada




Figura 21: Mapa variográfico


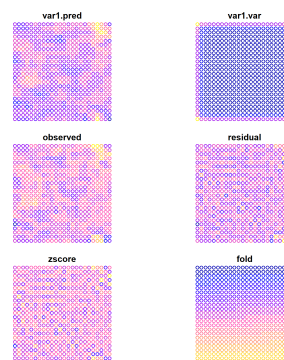


Figura 22: Contribuição espacial das variável mensurada



Fonte: Elaborado pelos Autores (2025)

Dando o enfoque no modelo esférico, determinados enfase nos parâmetros deste modelo. E passo que escolhemos o modelo, sendo que o resultado erro médio quadrático e a porcentagem explicada do modelo em quadra a seguir.

```

1 .0364868216565002 # root mean squared error
2 A matrix: 1 × 1 of type dbl
3 0.9465385 # % de explicacao do modelo

```

Listing 15: Resultado do modelo de superfície de tendencia de 3 grau saída da linguagem R

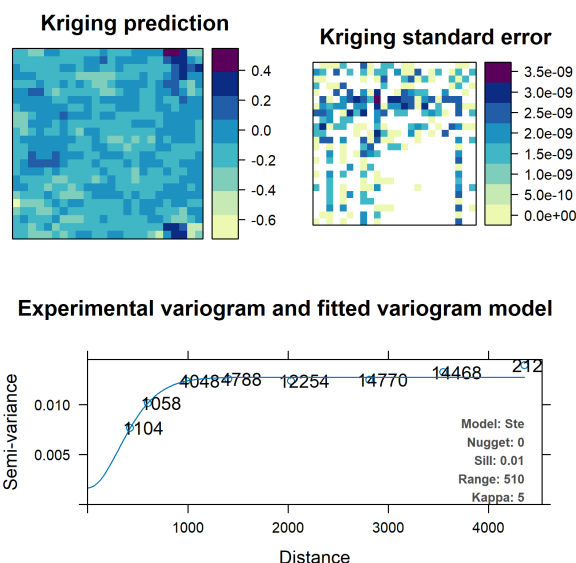
Realização



Apoio Institucional



Figura 23: Modelagem por krigagem



Fonte: Elaborado pelos Autores (2025)

O que nos animou a elaboração da krigagem em Figura 23, o que possibilita ao lado direito da figura os locais onde ocorrem os maiores erros, na determinação desta superfície. E para também o variograma ficou próximo ao da Figura 22

4.3 Análise da validação cruzada do Modelo

```

1  Lilliefors (Kolmogorov-Smirnov) normality test
2  data: valida3$pred
3  D = 0.024572, p-value = 0.5765
    
```

Listing 16: Resultado do Teste Lilliefors (Kolmogorov_Smirnov) R

Tabela 2: Resultado do Predição

cooks.distanc	dfbeta1	dfbeta2	dfbeta1_st	zscore	leverage
4.915116e-05	-3.618e-05	4.236e-06	-1.3644e-04	0.003093	0.003093860
1.067958e-03	-3.6184e-05	5.5829e-04	5.582e-04	-3.618e-05	0.0026221872
...
2.136032e-09	2.310e-08	5.582e-04	1.103e-06	2.310e-08	0.005113479

Fonte: Elaborado pelos Autores (2025)

```

1  Pearson s product-moment correlation
2
3  data:  Mod_esfe$pred and Mod_esfe$observed
    
```

Realização



Apoio Institucional



```
4 t = 24.657, df = 574, p-value < 2.2e-16
5 alternative hypothesis: true correlation is not equal to 0
6 95 percent confidence interval:
7 0.6750592 0.7546794
8 sample estimates:
9 cor
10 0.7172019
```

Listing 17: Resultado do Teste de Correlação em linguagem R

Figura 24: Distância de Cooks e Alavancagem



Figura 25: Análise gráfica da normalidade

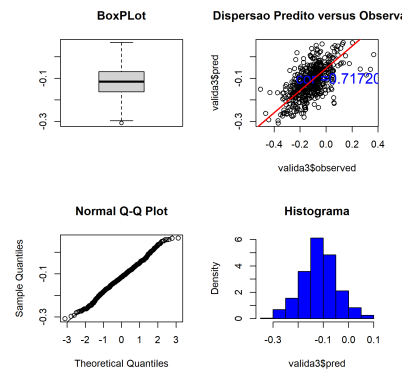
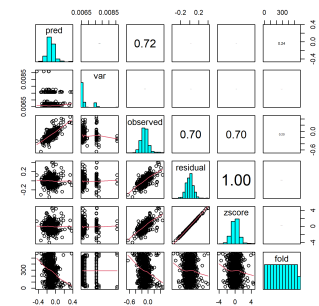


Figura 26: Análise gráfica da correlação entre variáveis




Fonte: Elaborado pelos Autores (2025)

4.4 Dinâmica temporal

E finalmente, passamos para a análise temporal, o qual escolhemos uma posição geográfica onde ocorrem uma maior variação deste modelo superficial de variações de reflectância, pode análise temporal entre as diferenças $\Delta T = T_2 - T_1$

Na Figura 27, mostra o comportamento anômalo de todos os índices espectrais ao início do ano de 2016, junto a margem.

Figura 27: Índices em análise temporal



Fonte: Elaborado pelos Autores (2025)


Realização



Apoio Institucional




Figura 28: Aumento do óxido de ferro no período



Fonte: Elaborado pelos Autores (2025)

A variação do óxido de ferro alcançou o máximo ao ano de 2018 como Figura 28

Figura 29: Índices NDVI e NDWI



Fonte: Elaborado pelos Autores (2025)

5 Discussão

Na proposta de avaliação dos impactos do lançamento de rejeitos de mineração próximo a foz do rio Doce. Se o local escolhido do estudo, através da técnicas de sensoriamento remoto, nos possibilita inferir as alterações do meio físico: antes, durante e depois do acidente.

Na primeira hipótese H_1 , avaliou-se se o sensor utilizado consegue discriminar os efeitos do evento. Conforme apresentado nos parágrafos 1 a 4 da seção 4 e nas Figuras 11 a 12, o índice NDWI revelou alterações perceptíveis na data próxima ao ocorrido, conforme ilustrado na Figura 9.

Em segunda hipótese H_1 , buscou-se uma explicação baseada em critérios matemáticos, com menor subjetividade na interpretação. Para tanto, utilizou-se a geoestatística como abordagem principal.

Inicialmente, a amostragem aleatória de classes de uso do solo foi testada, mas os resultados, avaliados por meio de normalidade, erro amostral, variância, coeficiente de determinação e métrica RMSE, mostraram-se ineficientes, explicando apenas 41% da variabilidade do modelo espacial.

Por outro lado, a amostragem em grade ("grid") conseguiu explicar aproximadamente 95% do modelo. Por isso, essa abordagem foi selecionada para a construção do semivariograma e sua representação espacial, incluindo os desvios-padrão.

A amplitude geográfica e a maior variabilidade dos resíduos indicaram os locais

Realização



Apoio Institucional



cobreap.com.br



producao@alvoeventos.com.br

onde o modelo de superfície tridimensional apresentou menor capacidade explicativa, sendo esses os pontos de maior atenção, com z-scores mais altos Figura 22 e desvios mais expressivos, representados por regiões mais escuras no mapa da Figura 23.

Portanto, a hipótese H_1 foi confirmada, indicando que o sensor foi sensível ao fenômeno e identificando áreas geográficas que demandam maior esforço de explicação.

Por fim, a terceira hipótese H_1 foi considerada a mais direta pelos autores. A extração dos valores de reflectância e seus índices, diretamente sobre os alvos/focos em locais com maior variabilidade temporal, foi ocasionada pelo fenômeno e detectada pelo sensor. Em termos simples, o que foge à normalidade pode ser considerado anômalo.

As coordenadas geográficas com menores valores de reflectância, em áreas sujeitas a alagamento, apresentaram as maiores distorções de reflectância ao longo do período analisado, conforme demonstrado nas Figuras 27 a 29. Após o evento, os valores de reflectância desses alvos retornaram à normalidade.

6 Conclusão

As Figuras 2 ilustram a situação local durante a inundação ocorrida em 2013. Já as Figuras 3 e 4 mostram a chegada de rejeitos à foz do rio Doce. Ambos os fenômenos foram detectados por sensores orbitais e pela população residente.

No presente estudo, a dinâmica territorial e espacial afetada pelo despejo de rejeitos de mineração foi analisada, consolidando a hipótese por meio de métodos matemáticos, especificamente a geoestatística, e de um painel temporal que descreve as alterações físicas do fenômeno..

Verificou-se que a amostragem por grade foi a mais apropriada para este estudo. Não ficou claro se a ausência de explicação sobre o modelo de amostragem aleatória decorreu de limitações metodológicas ou da falta de aprofundamento conceitual dessa técnica, uma vez que os procedimentos e algoritmos utilizados foram os mesmos.

A função esférica ajustou-se melhor aos dados, e tanto o processo automático, e utilizando krigagem, quanto o processo manual obtiveram parâmetros semelhantes, permitindo descrever os locais geográficos para estudos mais aprofundados.

A Figura 20 por meio da modularização para descrição e sumarização estatística da reflectância temporal, foi capaz de destacar pontos discrepantes relacionados ao fenômeno estudado. Esses pontos ou dados anômalos não foram excluídos na Figura 14.

Conforme recomendado pela própria metodologia geoestatística, estudos mais aprofundados devem ser direcionados aos locais onde o modelo apresentou dificuldades para explicar os fenômenos observados.

Realização



Apoio Institucional



cobreap.com.br



producao@alvoeventos.com.br

Referências

- ANDRIOTTI, J. L. S. **Fundamentos de Estatística e Geoestatística**. 2. ed. São Leopoldo, RS, Brasil: Unisinos, 2009. ISBN 8574311715. (Citado na página (page 9).)
- ARANTES, C. A.; ARANTES, C. **Perícia Ambiental: Aspectos Técnicos e Legais**. 2. ed. Birigui, SP: Boreal Editora, 2016. ISBN 9788599286562. (Citado na página (page 3).)
- BIVAND, R. S.; PEBESMA, E.; GOMEZ-RUBIO, V. **Applied Spatial Data Analysis with R**. 2. ed. London, UK: Springer, 2013. ISBN 9781461476177. (Citado 2 vezes nas páginas (page 9) e (page 18).)
- BOLFARINE, H. **Elementos de amostragem**. 4. ed. [S.l.]: Blucher, 2005. ISBN 9788521203674. (Citado na página (page 7).)
- CENTENO, J. A. S. **Sensoriamento Remoto e Processamento de Imagens Digitais**. Curitiba, PR -Brasil: Editora UFPR, 2003. ISBN 8535909559. (Citado 2 vezes nas páginas (page 6) e (page 7).)
- CHUVIECO, E. S. **Teledetección Ambiental: La observación de la Tierra**. 3. ed. Barcelona, Espanha: Ariel Ciencias, 2008. ISBN 9788434480733. (Citado na página (page 7).)
- CONGALTON, R. G.; GREEN, K. **Assessing the Accuracy of Remotely Sensed Data : Principles and Practices**. 2. ed. [S.l.]: CRC Press, 2009. ISBN 978-1-4200-5512-2. (Citado na página (page 8).)
- DORMAN, M. **Learnin R for Geospatial Analysis**. 1. ed. Birmanghm , UK: Packt Publishimn Ltda, 2014. ISBN 9781783984367. (Citado na página (page 10).)
- FERREIRA, M. C. **Iniciação a análise geoespacial: Teoria, Técnica e exemplos para geoprocessamento**. 3. ed. São Paulo, SP: Editora Unesp, 2014. 347 p. ISBN 978-85-393-0537-7. (Citado na página (page 13).)
- JENSEN, J. R. **Introductory digital processing: a remote sensing perspective**. 2015. ed. University of South Carolina, USA: Pearson Education, inc, 1949. v. 4. ISBN 9780134058160. (Citado na página (page 6).)
- KRISHNASWAMY, K. N.; SIVAKUMAR, A. I.; MATHIRAJAN, M. **Management Research Methodology: Integration of Principles, Methods and Techniques**. 1. ed. New Delhi, India: Pearson Education, 2012. ISBN 97881131798811. (Citado na página (page 7).)
- KUMAR, L.; MUTANGA, O. **Google Earth Engine Applications**. Basel, Switzerland: MDPI, 2019. 422 p. ISBN 978303897775. (Citado na página (page 4).)

Realização



Apoio Institucional



cobreap.com.br



producao@alvoeventos.com.br

LILLESAND, T. M.; KIEFE, R. **Remote Sensing and Interpretation**. 7. ed. Hoboken, USA: John Wiley and Sons, 2016. ISBN 8781118343289. (Citado na página (page 6).)

LIU, W. T. H. **Aplicações de sensoriamento remoto**. [S.l.]: Oficina dos Textos, 2015. ISBN 8577040400. (Citado na página (page 10).)

LOHS, S. L. **Sampling Design and Analysis**. 3. ed. [S.l.]: CRC Press, 2022. ISBN 9780129298899. (Citado na página (page 8).)

LOPES, F. J. A. **Calidad en la Producción Cartográfica**. Madri, Espanha: ra-ma, 2002. ISBN 9788478975242. (Citado 2 vezes nas páginas (page 8) e (page 9).)

MAGRI, P. P.; MARROS, J.; HARCIA, M. H.; NETO, A. C. **Pericia Ambiental: expertises e abordagens ambientais: Incidência de área de Preservação Permanente em Terreno Urbano**. Sao Paulos, SP: Leud Editora, 2023. ISBN 9788574564401. (Citado na página (page 3).)

MATEU, J.; MULLER, W. G. **Spatial-Temporal design: Advances in efficient data acquisition**. 2. ed. Chichester, UK: Wiley Publication, 2013. ISBN 9780470974292. (Citado na página (page 9).)

PEBESMA, E.; BIVAND, R. **Spatial Data Science with Applications in R**. 1. ed. New York, USA: CRC Press, 2023. ISBN 9781138311183. (Citado na página (page 7).)

REDDY, M. A. **Textbook of Remote Sensing and Geographical Information System**. 3. ed. Giriraj Lane, Sultan Bazar, India: BS Publications, 2008. 478 p. ISBN 978-81-7800-135-7. (Citado na página (page 6).)

SCHOWENGERDT, R. A. **Remote Sensing Models and Methods for Image Processing**. 3. ed. Tucson, Arizona, USA: Elvier, 2007. ISBN 9780123694072. (Citado na página (page 6).)

THENKABAIL, P. **Land Resousces monitoring , modeling, and mapping with remote sensing**. 1. ed. Boca Raton, FL, USA: CRC Press, 2016. ISBN 9781482217957. (Citado na página (page 10).)

TOLOSANA-DELGADO, R.; MUELLER, U. **Geostatistics for Compositional Data with R**. 1. ed. Cham, Switzerland: Springer, 2021. ISBN 9783030825683. (Citado 3 vezes nas páginas (page 9), (page 18) e (page 19).)

WEBSTER, R.; OLIVER, M. **Geostatistics for Environmental Scientists**. 2. ed. John Wily Sons , UK: Packt Publishimn Ltda, 2007. ISBN 978047002858. (Citado 2 vezes nas páginas (page 9) e (page 17).)

YAMAMOTO, J. K.; LANDIN, P. M. B. **Geoestatística: Conceitos + aplicacoes**. 1. ed. Sao Paulo, SP, Brasil: Oficina dos Textos, 2013. ISBN 9788579750779. (Citado 4 vezes nas páginas (page 9), (page 13), (page 16) e (page 17).)

Realização



Apoio Institucional



cobreap.com.br



producao@alvoeventos.com.br